

支持向量机算法

支持向量机(support vector machines, SVM)是一种监督学习算法, 可用于解决分类问题或回归问题。支持向量机算法在上世纪90年代初被提出并因之在文本分类领域的卓越表现得到推广认可, 目前广泛应用于人脸识别、图像分类、手写识别数字、垃圾邮件检测等业务领域。本章我们讲解支持向量机算法的基本原理, 并结合具体实例讲解该算法在python中解决分类问题和回归问题的实现与应用。

目录

C O N T E N T S

- 1 支持向量机算法的基本原理
- 2 数据准备
- 3 回归支持向量机算法示例
- 4 二分类支持向量机算法示例
- 5 多分类支持向量机算法示例
- 6 习 题




PART 01

支持向量机算法的基本原理

线性可分


在讲述支持向量机之前，首先需要了解什么是线性可分，如图所示，在二维空间上，如果响应变量为二分类变量，所有样本示例能够被一条直线按照类别分开，即称为线性可分。



线性可分

从数学公式的角度看，假定样本示例全集为 D ，响应变量为二分类变量，则可以按照响应变量类别将 D 切割为 D_1 和 D_2 。如果 x 为特征向量，存在 n 维向量 β 和实数 β_0 ，使得所有属于 D_1 的样本示例都能满足 $\beta_0 + \beta^T x > 0$ ，而所有属于 D_2 的样本示例都能满足 $\beta_0 + \beta^T x < 0$ ，当然 D_1 和 D_2 的地位可互换，即称 D_1 和 D_2 线性可分。

但需要注意的是，即使 D_1 和 D_2 线性可分，但分割线可能不止一条，如下图所示：




硬间隔分类器的概念与原理解释

在前述线性可分示例中，我们需要选择哪一条分割线作为最佳分割线呢？从结果具有更大稳健性的角度考虑，我们选择的分割线，应该使得两侧距离分割线最近的样本点到分割线的距离最远。对于线性可分的数据集来说，能够完成样本分割的分割线有无穷多个，但是几何间隔最大的分割线即最佳分割线却是唯一的。

更一般的，当空间从二维空间拓展到多维空间时，我们需要寻找的就是“最大间隔超平面”，以最大间隔把两类样本分开的超平面，也称之为最大间隔超平面。如果我们能够找到这个最大间隔超平面，那么对应的分类器就称为最大间隔分类器，最大间隔分类器也被称为硬间隔分类器。

硬间隔分类器的概念与原理解释

如下图所示，图中的虚线 L 就是最大间隔超平面， L^+ 称为“正间隔”， L^- 称为“负间隔”，样本示例中距离最大间隔超平面（虚线 L ）最近的样本点（本例中有 4 个）就是支持向量。支持向量到最大间隔超平面的距离为 d ，其他点到最大间隔超平面的距离大于 d ，“正间隔”与“负间隔”之间的距离为 d 的 2 倍，也被称为 margin 。基于支持向量求解最大间隔分类器的方法就是支持向量机算法。所以，支持向量机学习的基本想法就是求解能够正确划分样本数据集并且几何间隔最大的分离超平面。从以上概念中也可以看出，所谓最大间隔超平面其实也是前面章节中所讲述的决策边界的一种。



硬间隔分类器的概念与原理解释

支持向量机要找到最大间隔超平面，也就是使得各类样本点到超平面的距离最远。样本点 x 到直线 $L: \beta_0 + \beta^T x = 0$ 的距离为：

$$\frac{\beta_0 + \beta^T x}{\|\beta\|} \quad \text{其中 } \|\beta\| = \sqrt{\beta_1^2 + \beta_2^2 + \dots + \beta_n^2}$$

假设响应变量 y 有两种取值，图中右侧三角形的样本点均取值为 1，左侧圆形的样本点均取值为 -1，支持向量机要满足正确划分样本数据集的约束条件，就必须有：

$$\begin{cases} \frac{\beta_0 + \beta^T x}{\|\beta\|} \geq d & y = 1 \\ \frac{\beta_0 + \beta^T x}{\|\beta\|} \leq -d & y = -1 \end{cases}$$

变换后：

$$\begin{cases} \frac{\beta_0 + \beta^T x}{\|\beta\| d} \geq 1 & y = 1 \\ \frac{\beta_0 + \beta^T x}{\|\beta\| d} \leq -1 & y = -1 \end{cases}$$

硬间隔分类器的概念与原理解释

至此我们论述的都是线性函数，即 $f(x) = \beta_0 + \beta^T x$ ，且 $\|\beta\| d$ 为正数，所以一定可以通过线性变换的方式（也可以理解为 $\|\beta\|$ 与 d 融合）使得 $\|\beta\| d = 1$ ，即有 $d = \frac{1}{\|\beta\|}$ ：

$$\begin{cases} \beta_0 + \beta^T x \geq 1 & y = 1 \\ \beta_0 + \beta^T x \leq -1 & y = -1 \end{cases}$$

所以不论 y 取值为 1 还是 -1，约束条件都可以写为： $y(\beta_0 + \beta^T x) \geq 1$

因为正间隔、负间隔上的点都是距离最大间隔超平面最近的点，故对于在正间隔 L^+ 上的所有点能够满足 $L^+ : \beta_0 + \beta^T x = 1$ ，对于在负间隔 L^- 上的所有点能够满足 $L^- : \beta_0 + \beta^T x = -1$

正间隔和负间隔之间的间隔 $\text{margin} = 2d = \frac{2}{\|\beta\|}$ 。我们需求求解的问题最大化间隔就是：

$$\max \frac{2}{\|\beta\|} \quad \text{s.t.} \quad y(\beta_0 + \beta^T x) \geq 1$$

该问题等价于 $\min \frac{1}{2} \|\beta\|^2$ ，亦等价于 $\min \frac{1}{2} \|\beta\|^2 \quad \text{s.t.} \quad y(\beta_0 + \beta^T x) \geq 1$

硬间隔分类器的求解步骤

一、构建拉格朗日函数

由于目标函数是二次型，且约束条件为线性不等式约束，所以是凸二次规划问题，且不等式约束优化问题最优解需满足 KKT(Karush-Kuhn-Tucker) 条件（相关原理较为复杂，限于篇幅不再详解，可参阅相关统计学教材），构建以下的拉格朗日函数：

$$\min_{\beta, \beta_0} \max_{\lambda} L(\beta, \beta_0, \lambda) = \frac{1}{2} \|\beta\|^2 + \sum_{i=1}^n \lambda_i [1 - y_i(\beta^T x_i + b)] \quad \text{s.t. } \lambda_i \geq 0$$

二、强对偶性转化

强对偶性是指 $\min \max f() = \max \min f()$ ，在函数为凸二次规划问题时，强对偶性成立，KKT(Karush-Kuhn-Tucker)条件也是强对偶性的充分必要条件，即将上述问题转化为：

$$\max_{\lambda} \min_{\beta, \beta_0} L(\beta, \beta_0, \lambda) = \frac{1}{2} \|\beta\|^2 + \sum_{i=1}^n \lambda_i [1 - y_i(\beta^T x_i + b)] \quad \text{s.t. } \lambda_i \geq 0$$

硬间隔分类器的求解步骤

对上式中的参数 β, β_0 求偏导：

$$\begin{cases} \frac{\partial L}{\partial \beta} = \beta - \sum_{i=1}^n \lambda_i x_i y_i = 0 & \sum_{i=1}^n \lambda_i x_i y_i = \beta \\ \frac{\partial L}{\partial \beta_0} = \sum_{i=1}^n \lambda_i y_i = 0 & \sum_{i=1}^n \lambda_i y_i = 0 \end{cases}$$

将该结果带入前面的拉格朗日函数：

$$\begin{aligned} L(\beta, \beta_0, \lambda) &= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \lambda_i - \sum_{i=1}^n \lambda_i y_i \left(\sum_{j=1}^n \lambda_j y_j (x_i \cdot x_j) + \beta_0 \right) \\ &= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \lambda_i - \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^n \lambda_i y_i \beta_0 \\ &= \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) \end{aligned} \quad \text{即有：}$$

$$\min_{\beta, \beta_0} L(\beta, \beta_0, \lambda) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j)$$


$$\max_{\lambda} \left[\sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) \right] \quad \text{s.t.} \quad \sum_{i=1}^n \lambda_i y_i = 0, \lambda_i \geq 0$$

其中 $x_i \cdot x_j$ 为 x_i 和 x_j 的内积，等价于 $x_i^T x_j$ 。

该问题为二次规划问题，使用SMO(Sequential Minimal Optimization)，序列最小优化算法求解即可，该算法的基本思路是在保持其他参数固定的同时，每次只优化一个参数，仅求当前待优化参数的极值，具体求解过程略。


|| 软间隔分类器的概念与原理解释

在实践应用中，很多情形下并不能满足线性可分条件，或者说各类别之间并非是泾渭分明的，无法实现类别之间的完全分割，如下图：



|| 软间隔分类器的概念与原理解释


在这种情况下，我们应该退而求其次，允许少数样本点分布在间隔带（margin）里面，如下图所示：



软间隔分类器的概念与原理解释

从数学公式的角度，就是要允许少量样本点不再满足条件： $y_i(\beta_0 + \beta^T x_i) \geq 1$ 。相对于前面的完全分割或者称作“硬间隔”，这就是一种“软间隔”的概念，放松之后的支持向量机就是“软间隔分类器”。对于“软间隔分类器”来说，非常重要的参数就是相对于“硬间隔”而言，软的程度或者放松的程度如何，为了度量该“松弛程度”，我们需要引入松弛变量 ξ ，每一个样本示例均有 $\xi_i \geq 0$ ，原有条件变化为：

$$y_i(\beta_0 + \beta^T x_i) + \xi_i \geq 1$$



如上图所示，针对右侧的三角形样本示例而言，原有的条件为 $y_i(\beta_0 + \beta^T x_i) \geq 1$ ，现在有一个样本点进入到了间隔带里面，如果我们允许其进入间隔带，那么其在原有基础上加上我们允许的程度 ξ_i ，达到 $y_i(\beta_0 + \beta^T x_i) + \xi_i \geq 1$ 即可，这就是软间隔分类器的直观解释。

|| 软间隔分类器的概念与原理解释

此处常见的一个问题是，在间隔带内的样本示例是否是支持向量？答案是肯定的，间隔带内的样本示例也是支持向量，因为支持向量机算法的核心思想就是只有支持向量才会影响参数、影响间隔带的划分，其他的向量是不起作用的，而间隔带内的样本示例显然会通过影响松弛程度来影响模型的参数，所以也是支持向量。

|| 软间隔分类器的求解步骤

结合前述讲解，软间隔分类器的优化目标其实是如下最优化问题：

$$\min \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n \xi_i$$

$$\text{s.t. } y_i(\beta_0 + \beta^T x_i) + \xi_i \geq 1, \xi_i \geq 0, i = 1, 2, \dots, n$$

C 为大于 0 的常数，用于设置为错误分类样本的惩罚程度。

一、构建拉格朗日函数

$$\min_{\beta, \beta_0, \xi} \max_{\lambda, \mu} L(\beta, \beta_0, \xi, \lambda, \mu) = \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \lambda_i [1 - \xi_i - y_i(\beta^T x_i + b)] - \sum_{i=1}^n \mu_i \xi_i$$
$$\text{s.t. } \lambda_i \geq 0 \quad \mu_i \geq 0$$

|| 软间隔分类器的求解步骤

二、强对偶性转化

将上述问题转化为：

$$\begin{aligned} \max_{\lambda, \mu} \min_{\beta, \beta_0, \xi} L(\beta, \beta_0, \xi, \lambda, \mu) &= \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \lambda_i [1 - \xi_i - y_i(\beta^T x_i + b)] - \sum_{i=1}^n \mu_i \xi_i \\ \text{s.t. } \lambda_i &\geq 0 \quad \mu_i \geq 0 \end{aligned}$$

对上式中的参数 β, β_0, ξ_i 求偏导并转换，得到：

$$\begin{cases} \sum_{i=1}^n \lambda_i x_i y_i = \beta \\ \sum_{i=1}^n \lambda_i y_i = 0 \\ C = \lambda_i + \mu_i \end{cases}$$

将该结果带入前面的拉格朗日函数，得到：


$$\min_{\beta, \beta_0, \xi} L(\beta, \beta_0, \xi, \lambda, \mu) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j)$$

$$\max_{\lambda} \left[\sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i \cdot x_j) \right] \quad \text{s.t.} \quad \sum_{i=1}^n \lambda_i y_i = 0, \lambda_i \geq 0, C - \lambda_i - \mu_i = 0$$

可以发现相对于前面的硬间隔分类器，只是多了 $C - \lambda_i - \mu_i = 0$ 的约束条件，同样使用序列最小优化算法求解即可，具体求解过程略。

核函数

前面我们讲解的硬间隔分类器和软间隔分类器，不论是硬间隔下的所有样本示例完全线性可分，还是软间隔下的大部分样本示例线性可分，都基于线性可分的概念，但是还有一种常见的情况就是样本点不是线性可分的，呈现的是非线性关系（如下面左图所示）。



核函数

如果在二维空间无法实现线性可分，通常的做法就是选择一个非线性变换函数 $\phi(x)$ ，将特征变量 x 映射到高维特征空间成为 $\phi(x)$ ，或者说将样本示例由 $\{x_i, y_i\}$ 变换成为 $\{\phi(x_i), y_i\}$ 让样本点在高维空间线性可分（如上面右图所示），再通过间隔最大化的方式，学习得到支持向量机，这也就是非线性支持向量机的基本原理。可以证明，如果原始空间的维数是有限的，那么一定存在高维特征空间使样本示例可分。

在进行 $\phi(x)$ 变换后，优化目标为如下最优化问题：

$$\min \frac{1}{2} \|\beta\|^2$$

$$\text{s.t. } y_i(\beta_0 + \beta^T \phi(x_i)) \geq 1, i = 1, 2, \dots, n$$

对偶问题为：

$$\max_{\lambda} \left[\sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (\phi(x_i)^T \phi(x_j)) \right] \quad \text{s.t. } \sum_{i=1}^n \lambda_i y_i = 0, \lambda_i \geq 0, i = 1, 2, \dots, n$$

在该表达式中， $\phi(x)$ 难以确定，但好在我们并不必然需要得到 $\phi(x)$ 的具体形式，支持向量机的结果仅依赖于 $\phi(x_i)$ 与 $\phi(x_j)$ 的内积。我们把 $\phi(x_i)$ 与 $\phi(x_j)$ 的内积定义为核函数：

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$

也就是说，只要找到了恰当的核函数，或者说直接指定核函数的具体形式，就能够开展支持向量机算法估计，支持向量机通过核函数展开的方式称为“支持向量展开”，这一方法也称为“核技巧”。

核函数

在核函数 $K\{x_i, x_j\}$ 中, x_i 和 x_j 的地位是对称的, 核矩阵 K 总是半正定的:

$$K = \begin{pmatrix} K(x_1, x_1) & \cdots & K(x_1, x_n) \\ \vdots & \ddots & \vdots \\ K(x_n, x_1) & \cdots & K(x_n, x_n) \end{pmatrix}$$

只要一个对称函数所对应的核矩阵半正定, 就可以作为核函数使用; 同时对于任意一个核函数, 都能将样本示例映射到一个特征空间。所以, 核函数的选择是多样化的, 核函数的选择也决定了模型的性能, 如果核函数选择不好, 那么就会将样本示例映射到一个并不合适的特征空间, 从这种意义上讲, 核函数的选择是支持向量机算法的精髓和关键之所在。

常用的核函数包括:

1、多项式核函数 (polynomial kernel)

$$K(x_i, x_j) = (1 + \gamma x_i^T x_j)^d$$

公式中 d 是多项式的次数, $d \geq 1$, $\gamma > 0$ 为参数。特别的, 如果 $d = 1$, 那么就退化为线性核函数, 或者说没有进行非线性变换, 可直接设置为 $K(x_i, x_j) = x_i^T x_j$

2、径向基函数 (radial kernel 或 radial basis function, RBF)

$$K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|^2} \quad \gamma > 0$$

因为径向基函数非常接近正态分布的密度函数, 所以也被称为 高斯核函数。公式中 $\|\cdot\|$ 为欧氏距离 (2-范数), 使用的是欧式距离的平方, γ 为径向基函数的参数, 用于控制一个样本点的影响范围, 如果设置过大则通过 “ $-\gamma$ ” 使得一个样本点的影响范围很小, 会导致欠拟合; 而如果设置过小, 则通过 “ $-\gamma$ ” 使得一个样本点的影响范围很大, 会导致过拟合。

3、拉普拉斯核函数 (Laplacian kernel)

$$K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|} \quad \gamma > 0$$

拉普拉斯核函数使用 $\|x_i - x_j\|$ 欧式距离，而非欧式距离的平方，参数 γ 的含义与径向基函数相同。

4、S 型核函数 (sigmoid kernel)

$$K(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta) \quad \beta > 0, \theta < 0$$

公式中的 $\tanh()$ 为双曲正切函数， $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ ，该函数常用作人工神经网络中的激活函数。

此外，还可以通过组合的方式得到核函数。

若 K_1 和 K_2 均为核函数，那么其线性组合 $\gamma_1 K_1 + \gamma_2 K_2$ 也为核函数，其中 γ_1 、 γ_2 须为正数。

若 K_1 和 K_2 均为核函数，那么核函数的直积 $K_1 \otimes K_2$ 也为核函数。

若 K_1 为核函数，那么对于任意函数 $f(x)$ ， $K(x_i, x_j) = f(x_i)K_1(x_i, x_j)f(x_j)$ 也为核函数。

需要说明的是，“核技巧”的应用并不局限于支持向量机算法，也可用于其他机器学习算法。针对支持向量机算法，采用核技巧之后，可以处理非线性分类/回归任务，能找出对优化目标至关重要的关键样本示例，而且最终决策函数只由少数的支持向量所确定，计算的复杂性取决于支持向量的数目，而不是样本空间的维数，在很大程度上实现了降维，能够较好的解决“维数灾难”问题。但是预测时间与支持向量的个数成正比，当支持向量的数量较大时，预测计算复杂度较高，所以支持向量机目前只适合小批量样本任务，无法较好的胜任大数据处理任务。

3、拉普拉斯核函数 (Laplacian kernel)

$$K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|} \quad \gamma > 0$$

拉普拉斯核函数使用 $\|x_i - x_j\|$ 欧式距离，而非欧式距离的平方，参数 γ 的含义与径向基函数相同。

4、S 型核函数 (sigmoid kernel)

$$K(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta) \quad \beta > 0, \theta < 0$$

公式中的 $\tanh()$ 为双曲正切函数， $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ ，该函数常用作人工神经网络中的激活函数。

此外，还可以通过组合的方式得到核函数。

若 K_1 和 K_2 均为核函数，那么其线性组合 $\gamma_1 K_1 + \gamma_2 K_2$ 也为核函数，其中 γ_1 、 γ_2 须为正数。

若 K_1 和 K_2 均为核函数，那么核函数的直积 $K_1 \otimes K_2$ 也为核函数。

若 K_1 为核函数，那么对于任意函数 $f(x)$ ， $K(x_i, x_j) = f(x_i)K_1(x_i, x_j)f(x_j)$ 也为核函数。

需要说明的是，“核技巧”的应用并不局限于支持向量机算法，也可用于其他机器学习算法。针对支持向量机算法，采用核技巧之后，可以处理非线性分类/回归任务，能找出对优化目标至关重要的关键样本示例，而且最终决策函数只由少数的支持向量所确定，计算的复杂性取决于支持向量的数目，而不是样本空间的维数，在很大程度上实现了降维，能够较好的解决“维数灾难”问题。但是预测时间与支持向量的个数成正比，当支持向量的数量较大时，预测计算复杂度较高，所以支持向量机目前只适合小批量样本任务，无法较好的胜任大数据处理任务。

3、拉普拉斯核函数 (Laplacian kernel)

$$K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|} \quad \gamma > 0$$

拉普拉斯核函数使用 $\|x_i - x_j\|$ 欧式距离，而非欧式距离的平方，参数 γ 的含义与径向基函数相同。

4、S 型核函数 (sigmoid kernel)

$$K(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta) \quad \beta > 0, \theta < 0$$

公式中的 $\tanh()$ 为双曲正切函数， $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ ，该函数常用作人工神经网络中的激活函数。

此外，还可以通过组合的方式得到核函数。

若 K_1 和 K_2 均为核函数，那么其线性组合 $\gamma_1 K_1 + \gamma_2 K_2$ 也为核函数，其中 γ_1 、 γ_2 须为正数。

若 K_1 和 K_2 均为核函数，那么核函数的直积 $K_1 \otimes K_2$ 也为核函数。

若 K_1 为核函数，那么对于任意函数 $f(x)$ ， $K(x_i, x_j) = f(x_i)K_1(x_i, x_j)f(x_j)$ 也为核函数。

需要说明的是，“核技巧”的应用并不局限于支持向量机算法，也可用于其他机器学习算法。针对支持向量机算法，采用核技巧之后，可以处理非线性分类/回归任务，能找出对优化目标至关重要的关键样本示例，而且最终决策函数只由少数的支持向量所确定，计算的复杂性取决于支持向量的数目，而不是样本空间的维数，在很大程度上实现了降维，能够较好的解决“维数灾难”问题。但是预测时间与支持向量的个数成正比，当支持向量的数量较大时，预测计算复杂度较高，所以支持向量机目前只适合小批量样本任务，无法较好的胜任大数据处理任务。

多分类问题支持向量机

前面我们讲述的支持向量机都是针对二分类问题，事实上，因为支持向量机的基本思想就是找到最优超平面对样本示例进行分割，所以无法自然的推广到多分类问题。当然，这并不意味着支持向量机无法应用于多分类问题，解决方法包括不限于：

1、直接修改目标函数：将多分类问题中的多个参数整合到一个函数中；

2、One-Versus-Rest（一对多）：训练时依次把某个类别的样本归为一类，其他类别样本归为另一类， K 个类别样本共可构造 K 个支持向量机模型。分类时将未知样本分类为具有最大分类函数值的那类。

3、One-Versus-One（一对一）：

这是最常用、也最有效的方法，其实现过程为：

假定样本示例全集为 D ，共有 K 个类别，然后从 K 个类别中选择两类的组合方式共有 C_K^2 种：


$$C_K^2 = \frac{K(K-1)}{2}$$

首先基于训练样本，分别构建这 C_K^2 个组合的支持向量机模型，共可得到 $\frac{K(K-1)}{2}$ 个模型，

对于测试样本，用这 $\frac{K(K-1)}{2}$ 个模型进行预测，按照多数票原则以最常见类别作为最终预测结果。

支持向量回归

支持向量机最初仅用于分类问题，后来推广到回归问题。我们考虑样本示例 $\{x_i, y_i\}$ ，在传统的回归算法下，其损失基于模型预测值 $f(x_i)$ 和真实值 y_i 之间的差别，当 $f(x_i)$ 与 y_i 完全相等时，损失才等于0。而根据支持向量回归的思想，我们应该能够容忍在 ε 范围内的偏离，（类似于软间隔分类器中的松弛程度 ξ_i ），只有当偏离在 ε 范围以外时，才认定为损失。或者说在 margin 范围内的样本示例被认为是预测正确的。



支持向量回归

设回归函数（最优超平面）为 $f(x) = \beta_0 + \beta^T x$ ，支持向量回归的目标函数即为：


$$\min_{\beta, \beta_0} \frac{1}{2} \beta^T \beta + C \sum_{i=1}^n \iota_{\varepsilon}[y_i - f(x_i)]$$

$C > 0$ 为正则化参数， $z_i \equiv y_i - f(x_i)$ 为残差。

在公式中 $\iota_{\varepsilon}()$ 为 ε -不敏感损失函数：

$$\iota_{\varepsilon}(z_i) = \begin{cases} 0 & |z_i| \leq \varepsilon \\ |z_i| - \varepsilon & |z_i| > \varepsilon \end{cases} \quad \text{其中 } \varepsilon > 0 \text{ 为调节参数}$$

下图直观的展示了 ε -不敏感损失函数，与之进行对比的是将残差平方 $\iota(z) = z^2$ 作为损失， ε -不敏感损失函数在 $|z_i| \leq \varepsilon$ 取值为 0，而在 $|z_i| > \varepsilon$ 时则取值为 $|z_i| - \varepsilon$ ，呈现线性增长。



|| 支持向量回归

由于在支持向量回归中使用了 ε -不敏感损失函数，所以支持向量回归也称 ε -回归。相对于传统回归模型，支持向量回归由于提高了容忍度，所以当数据集存在异常值时，结果更加具有鲁棒性（稳健性），此外，在支持向量回归中也可以使用核技巧对特征变量进行变换，得到非线性回归结果，所以支持向量回归具有独特的优势。针对支持向量回归目标函数的求解，同样可以通过引入松弛变量的方式，限于篇幅不再详述。

在前面各节中，我们介绍了各类支持向量机的原理与思想。不难发现，支持向量机比较适用于特征变量较多的数据集，这是因为高维空间内的样本示例较为分散，可以更好的使用最优超平面分割，这也是该方法相对于其他机器学习算法的最大优势，也正是基于该优势，支持向量机被广泛应用于人脸识别、图像分类、手写识别数字、垃圾邮件检测等领域。此外，因为支持向量机算法在预测时仅考虑作为支持向量的样本点，所以在数据存储空间也具有着相对更高的效率。而核技巧的引入，则使得支持向量机更具备通用性，可以解决高度非线性问题，所以从整体上看，该算法优势比较明显。



PART 02

数据准备

数据准备

本章我们用到的数据为上一章中介绍的“数据15.1”“数据13.1”“数据15.2”。

针对“数据15.1”，我们以pb为响应变量，以roe、debt、assetturnover、rdgrow、roic、rop、netincomeprofit、quickratio、incomegrow、netprofitgrow、cashflowgrow为特征变量，使用支持向量回归算法进行拟合。

针对“数据13.1”，我们以是否发生违约（credit）为响应变量，以年龄（age）、受教育程度（education）、工作年限（workyears）、居住年限（resideyears）、年收入水平（income）、债务收入比（debtratio）、信用卡负债（creditdebt）、其他负债（otherdebt）为特征变量，使用二分类支持向量机算法进行拟合。

针对“数据15.2”，我们以grade为响应变量，以age、marry、years、income、education、consume、work、gender、family为特征变量，使用多分类支持向量机算法进行拟合。

载入分析所需要的模块和函数

在进行分析之前，我们首先载入分析所需要的模块和函数，读取数据集并进行观察。

示例

参阅教材内容

PART 03

回归支持向量机算法示例

|| 变量设置及数据处理

示例

参阅教材内容

|| 回归支持向量机算法（默认参数）

- 一、线性核函数算法
- 二、多项式核函数算法
- 三、径向基函数算法
- 四、sigmoid核函数算法

示例

参阅教材内容

通过K折交叉验证寻求最优参数

- 一、线性核函数算法
- 二、多项式核函数算法
- 三、sigmoid核函数算法
- 四、径向基函数算法

示例

参阅教材内容

|| 最优模型拟合效果图形展示

示例

参阅教材内容

PART 04

二分类支持向量机算法示例

|| 变量设置及数据处理

示例

参阅教材内容

|| 二分类支持向量机算法（默认参数）

示例

参阅教材内容

|| 通过K折交叉验证寻求最优参数

示例

参阅教材内容

模型性能评价

示例

参阅教材内容

|| 绘制ROC曲线

示例

参阅教材内容

|| 运用两个特征变量绘制二分类支持向量机算法决策边界图

示例

参阅教材内容

PART 05

多分类支持向量机算法示例

|| 变量设置及数据处理

示例

参阅教材内容

多分类支持向量机算法（一对一）

示例

参阅教材内容

多分类支持向量机算法（默认参数）

示例

参阅教材内容

|| 通过K折交叉验证寻求最优参数

示例

参阅教材内容

模型性能评价

示例

参阅教材内容



PART 06

习 题

针对“数据6.1”（在第6章中已详细介绍），我们以收入档次（V1）为响应变量，以工作年限（V2）、绩效考核得分（V3）和违规操作积分（V4）为特征变量，使用多分类支持向量机算法进行拟合。

- (1) 变量设置及数据处理
- (2) 多分类支持向量机算法（一对一）
- (3) 多分类支持向量机算法（默认参数）
- (4) 通过K折交叉验证寻求最优参数
- (5) 模型性能评价