

第十四章 随机森林算法

在前面“3.8.5模型融合”一节中，我们讲述了使用模型融合提升算法准确度的方法，即训练多个模型（基学习器），然后按照一定的方法集成在一起（强学习器），常用的实现路径包括Bagging方法（装袋法、随机森林）和Boosting方法（提升法），在接下来的两章中我们将分别进行讲解。由于装袋法只是随机森林的一种特例，所以本章我们讲解随机森林算法的基本原理，并结合具体实例讲解该算法在python中解决分类问题和回归问题的实现与应用。

目录

C O N T E N T S

- 14.1 随机森林算法的基本原理
- 14.2 数据准备
- 14.3 分类问题随机森林算法示例
- 14.4 回归问题随机森林算法示例
- 14.5 习 题



PART 01

随机森林算法的基本原理

集成学习的概念与分类

前面我们讲述的线性回归、K近邻、决策树等算法都是单一的个体学习器，在样本容量有限的条件下，其能够实现的算法模型性能提升的空间较为有限。于是，统计学家们想出了一种集成学习（组合学习、模型融合）的方式，即将单一的个体学习器（基学习器）组合在一起，通过群策群力形成强学习器、达成模型性能的提升。

集成学习注重基学习器的优良性与差异性，通常情况下，如果每个基学习器在保证较高的分类准确率的同时，相互之间又能有较大的差异性，集成学习的效果就会充分得到显现（该理论由Krogh和Vedelsby于1995年提出，又称“误差-分歧分解”）。

集成学习的概念与分类

针对个体学习器的不同，集成学习可以分为同质学习和异质学习。

如果基学习器分别属于不同的类型，比如有线性回归模型、有决策树模型、有K近邻模型等，则通过分别赋予这些模型一定权重的方式（最优权重可以通过交叉验证的方式确定），加权得到最优预测模型，基于该思想的集成学习方式即为异质学习集成。

而如果这些基学习器都属于一个类型，比如均为决策树模型，那么在基准模型不变的条件下，可以通过搅动数据的方式，得到多个基学习器，然后进行模型融合，得到最优预测模型，基于该思想的集成学习方法即为同质学习集成。

集成学习的概念与分类

针对集成方法的不同，集成学习可以分为并行集成和串行集成。

如果基学习器间存在强依赖的关系，后一个基学习器的生成需依赖前一个基学习器的结果，则集成学习方式为串行集成，代表算法为Boosting，包括AdaBoost、GBDT、XGBoost等。

如果基学习器间不存在依赖关系，可以同时训练多个学习器，适合分布式并行计算，则集成学习方式为并行集成，代表算法为装袋法（Bagging）、随机森林算法，其中装袋法是随机森林算法一种特例。

|| 装袋法的概念与原理

首先我们来介绍装袋法，其实现过程是：

- 1、首先假设样本示例全集为 D ，通过自助法（详见3.7.3自助法一节介绍）对 D 进行 n 次有放回的抽样，形成 n 个训练样本集，并将在 n 次有放回的抽样中一次也没有被抽到过的样本示例构成包外测试集；
- 2、然后基于 n 个训练样本集生成 n 个基学习器（比如 n 颗决策树）；
- 3、再后基于包外测试集使用这 n 个基学习器对包外测试集进行预测，从而得到 n 个预测结果，如果是分类问题，就是 n 个分类，如果是回归问题，就是 n 个预测值。
- 4、如果是分类问题，按照“多数票规则”，将 n 个基学习器产生的预测值中取值最多的分类作为最终预测分类；如果是回归问题，将 n 个基学习器产生的预测值进行平均，以平均值作为最终预测值。
- 5、如果是分类问题，以袋外错误率作为评价最终模型的标准；如果是回归问题，以袋外均方误差或拟合优度作为评价最终模型的标准。

装袋法的概念与原理

装袋法一方面由于并不进行修枝，所以相对基学习器并未降低模型偏差，另一方面则由于将很多基学习器进行平均，所以优化了模型的方差（variance，或称模型的鲁棒性）。可以证明如果 n 个基学习器之间是独立同分布（方差均为 δ^2 ）的，那么在装袋法下由于进行了平均，模型融合的方差变成了 $\frac{\delta^2}{n}$ ， n 越大，方差下降的越为明显。所以，装袋法尤其适用于方差较大的不稳定估计量，或者说样本数据的轻微扰动可能会引起估计结果较大变化时的情形。比如线性回归、不剪枝决策树、神经网络等，而不太适用与 K 近邻算法等方差较小的稳定估计。

所以一个不容忽视的事实是，装袋法在基学习器之间服从独立同分布时特别有效，但在实务中这一条件经常不能够被很好的满足。比如针对决策树模型，在众多特征变量之中可能只有个别特征变量在模型拟合中起到了关键作用，或者说特征变量之间的重要性水平差别很远，那么可以合理预期的是，即使数据搅动再为充分，大多数基学习器可能都倾向于选择那些关键特征变量，使得基学习器之间存在较强的相关性或近似性，对这些高度相关的基学习器求平均并不能带来模型融合方差的显著降低，或者可以理解为，虽然样本数据搅动了，但基学习器没有与之进行相应变化，样本数据搅动的效果有限。

随机森林算法的概念与原理

为了较好的解决这一问题，统计学家又提出了随机森林算法（random forests method），随机森林是对装袋法的一种改进，与装袋法相同，随机森林也需要通过自助法进行 n 次有放回的抽样，形成 n 个训练样本集以及包外测试集，其不同之处在于，装袋法在构建基分类器时，将所有特征变量（假设为 p 个）都考虑进去，而随机森林在构建基分类器的时候，则从全部 p 个特征变量中随机抽取 m 个。比如针对前面所述的决策树模型，虽然有一些关键特征向量，但是受“随机抽取特征变量”这一规则限制，这些关键特征向量将不再像装袋法那些会被所有基分类器选择，从而保障了基分类器之间的多样性或差异性，从而使得样本搅动能够产生出应有的效果，达到降低模型融合方差的目的。当然，同样由于“随机抽取特征变量”这一规则限制，使得子分类器难以基于全部特征变量做出最优选择，从而同步提升了模型的偏差，这同样也是一个“方差-偏差”统筹权衡的问题。

那么随机抽取的特征变量个数 m 究竟为多少合适？实务中针对回归基学习器通常采用 $m = \frac{p}{3}$ ；而针对分类基学习器通常采用 $m = \sqrt{p}$ 不难发现，如果 $m = p$ ，即将全部特征变量作为随机抽取变量，那么随机森林算法也就变成了装袋法，所以，装袋法是随机森林算法一种特例。

|| 随机森林算法特征变量重要性度量

随机森林算法包含很多基学习器，那么如何度量各个特征变量的重要性水平？基学习器以决策树为例，首先针对单颗决策树计算重要性水平，即因采纳该变量引起的残差平方和（或信息增益、信息增益率、基尼指数等指标）变化的幅度；然后将随机森林中的所有决策树进行平均，即得到该变量对于整个随机森林的重要性水平。残差平方和下降或基尼指数下降越多、信息增益或信息增益率提升越多，说明变量在随机森林模型中越为重要。

部分依赖图与个体条件期望图

长期以来机器学习因其弱解释性深受诟病，所以很多专家学者深耕于可解释机器学习领域，奋力使模型结果具备可解释性。部分依赖图（Partial Dependence Plot）与个体条件期望图（ICEPlot）即是其中方法之一，在随机森林等集成学习算法中也经常被使用。其中部分依赖图显示了一个或两个特征变量对机器学习模型的预测结果的边际效应。与前面介绍的特征变量重要性不同，特征变量重要性展示的是哪些变量对预测的影响最大，而部分依赖图则展示的是特征如何影响模型预测的，可以显示响应变量和特征变量之间的关系是线性的、单调的还是更复杂的。个体条件期望图展示是每个样本示例预测值与选定特征变量之间的关系，其实现路径是，对特定样本示例，在保持其他特征变量不变的同时，变换选定特征变量的取值，并输出预测结果，从而实现了样本示例预测值随选定特征变量的变化情况。



PART 02

数据准备

数据准备

本节我们继续以上一章中的“数据13.1”和“数据13.2”为例进行讲解。针对“数据13.1”，我们以是否发生违约 (credit) 为响应变量，以年龄 (age)、受教育程度 (education)、工作年限 (workyears)、居住年限 (resideyears)、年收入水平 (income)、债务收入比 (debtratio)、信用卡负债 (creditdebt)、其他负债 (otherdebt) 为特征变量，使用分类随机森林算法进行拟合。

针对“数据13.2”，我们以“净资产收益率 (roe)”为响应变量，以第一大股东的持股量 (top1)、前五大股东的持股量 (top5)、前十大股东的持股量 (top10)、第一大股东持股量的平方项 (stop1)、前五大股东持股量的平方项 (stop5)、前十大股东持股量的平方项 (stop10) 为特征变量，使用回归随机森林算法进行拟合。

载入分析所需要的模块和函数

在进行分析之前，我们首先载入分析所需要的模块和函数，读取数据集并进行观察。

示例

参阅教材内容

PART 03

分类问题随机森林算法示例

|| 变量设置及数据处理

示例

参阅教材内容

|| 二元Logistic回归、单颗分类决策树算法观察

一、二元Logistic回归算法

示例

参阅教材内容

|| 二元Logistic回归、单颗分类决策树算法观察

二、单颗分类决策树算法

示例

参阅教材内容

|| 装袋法分类算法

示例

参阅教材内容

|| 随机森林分类算法

示例

参阅教材内容

|| 寻求max_features最优参数

示例

参阅教材内容

|| 寻求n_estimators最优参数

示例

参阅教材内容

|| 随机森林特征变量重要性水平分析

示例

参阅教材内容

|| 绘制部分依赖图与个体条件期望图

示例

参阅教材内容

模型性能评价

示例

参阅教材内容

|| 绘制ROC曲线

示例

参阅教材内容

|| 运用两个特征变量绘制随机森林算法决策边界图

示例

参阅教材内容

PART 04

回归问题随机森林算法示例

|| 变量设置及数据处理

示例

参阅教材内容

线性回归、单颗回归决策树算法观察

一、线性回归算法

二、单颗回归决策树算法

示例

参阅教材内容

|| 装袋法回归算法

示例

参阅教材内容

|| 随机森林回归算法

示例

参阅教材内容

|| 寻求max_features最优参数

示例

参阅教材内容

|| 寻求n_estimators最优参数

示例

参阅教材内容

|| 随机森林特征变量重要性水平分析

示例

参阅教材内容

|| 绘制部分依赖图与个体条件期望图

示例

参阅教材内容

|| 最优模型拟合效果图形展示

示例

参阅教材内容



PART 05

习 题

习题

1、使用“数据5.1”数据文件（详情已在第5章中介绍），把响应变量设定为“V1征信违约记录”，将其他变量作为特征变量，具体包括“V2资产负债率”、“V6主营业务收入”、“V7利息保障倍数”、“V14银行负债”、“V9其他渠道负债”，构建随机森林分类算法模型。

- (1) 变量设置及数据处理
- (2) 二元Logistic回归、单颗分类决策树算法观察
- (3) 装袋法分类算法
- (4) 随机森林分类算法

- (5) 寻求max_features最优参数
- (6) 寻求n_estimators最优参数
- (7) 随机森林特征变量重要性水平分析
- (8) 绘制部分依赖图与个体条件期望图
- (9) 模型性能评价
- (10) 绘制ROC曲线
- (11) 运用两个特征变量绘制随机森林算法决策边界图

2、使用“数据4.3”数据文件（详情已在第4章习题部分中介绍），Profit contribution为利润贡献度，作为响应变量；Net interest income为净利息收入、Intermediate income为中间业务收入、Deposit and finance daily为日均存款加理财之和，均作为特征变量，构建随机森林回归算法模型。

- (1) 变量设置及数据处理
- (2) 线性回归、单颗分类决策树算法观察
- (3) 装袋法回归算法
- (4) 随机森林回归算法

- (5) 寻求max_features最优参数
- (6) 寻求n_estimators最优参数
- (7) 随机森林特征变量重要性水平分析
- (8) 绘制部分依赖图与个体条件期望图
- (9) 最优模型拟合效果图形展示



感谢聆听

THANKS
