

Python 实现深度神经网络 RNN-LSTM 分类模型(医学疾病诊断)

1. 项目背景

随着互联网+的不断深入，我们已步入人工智能时代，机器学习作为人工智能的一个分支越来越多地被应用于各行各业，其中在临床医学检测中也得到了越来越多的应用。基于临床医学越来越多的检测数据，通过建立一个机器学习模型来进行更加智能地预测已成为当今时代的使命。本模型也是基于一些历史的疾病数据进行建模、预测。

2. 收集数据

本数据是模拟数据，分为两部分数据：

训练数据集：data.csv

测试数据集：test.csv

在实际应用中，根据自己的数据进行替换即可。

特征数据：age、gender、body_mass_index、heart_failurehypertension、
chronic_obstructic_pulmonary_disease、
chronic_liver_disease、.....renal_toxic_drug

标签数据：acute_kidney_disease

3. 数据预处理

1) 原始数据描述：

```
   age  gender  ...  renal_toxic_drug  acute_kidney_disease
0   50      0  ...                1                0
1   84      1  ...                0                0
2   54      1  ...                0                1
3   78      1  ...                0                0
4   55      0  ...                1                1

[5 rows x 29 columns]
```

2) 数据完整性、数据类型查看:

age	int64
gender	int64
body_mass_index	float64
heart_failure	int64
hypertension	int64
chronic_obstructic_pulmonary_disease	int64
chronic_liver_disease	int64
diabetes_mellitus	int64
chroinc_kidney_disease	int64
charlson	int64
emergency	int64
surgery	int64
APSI	int64
SAPSII	int64
non_renal_sofa-1	int64
non_renal_sofa-3	int64
non_renal_sofa	int64
aki_stage	int64
creatinine_baseline	float64
creatinine-1	float64
creatinine-3	float64

creatinine	float64
urine_output-1	float64
urine_output-3	float64
urine_output	float64
diuretic	int64
mechanical_ventilation	int64
renal_toxic_drug	int64
acute_kidney_disease	int64

3) 数据缺失值个数:


age	False
gender	False
body_mass_index	False
heart_failure	False
hypertension	False
chronic_obstructive_pulmonary_disease	False
chronic_liver_disease	False
diabetes_mellitus	False
chronic_kidney_disease	False
charlson	False
emergency	False
surgery	False
APSIII	False
SAPSII	False
non_renal_sofa-1	False
non_renal_sofa-3	False
non_renal_sofa	False
aki_stage	False
creatinine_baseline	False
creatinine-1	False
creatinine-3	False

creatinine	False
urine_output-1	False
urine_output-3	False
urine_output	False
diuretic	False
mechanical_ventilation	False
renal_toxic_drug	False
acute_kidney_disease	False
dtype: bool	


可以看到数据不存在缺失值。

4. 探索性数据分析


1) 显示 age 特征的分布情况:



2) 显示 gender 特征的分布情况:





3) 显示 heart_failure 特征的分布情况:



剩下的其它特征，可以自行分析。

4) 相关性分析





说明：正值是正相关、负值时负相关，值越大变量之间的相关性越强。

5. 特征工程

1) 特征数据和标签数据拆分，acute_kidney_disease 为标签数据，除 acute_kidney_disease 之外的为特征数据；

```
X_train = data_train.drop(['acute_kidney_disease'], axis=1)
y_train = data_train['acute_kidney_disease']
```

2) 数据集拆分，分为训练集和尝试集

```
data_train = pd.read_csv("data.csv")
print(data_train.head())
```

```
data_test = pd.read_csv("test.csv")
print(data_test.head())
```

数据集已提前分好，直接读取即可。

6. LSTM 建模

1) 神经网络 LSTM 简单介绍：


LSTM 网络是 RNN 的一个变体，也是目前更加通用的循环神经网络结构，全程为 Long Short-Term Memory，翻译成中文叫作”长 ‘短记忆’ ”网络。读

的时候，”长”后面要稍作停顿，不要读成”长短”记忆网络，因为那样的话，就不知道记忆到底是长还是短。本质上，它还是短记忆网络，只是用某种方法把”短记忆”尽可能延长了一些。

简而言之，LSTM 就是携带一条记忆轨道的循环神经网络，是专门针对梯度消失问题所做的改进。它增加的记忆轨道是一种携带信息跨越多个时间步的方法。可以先想象有一条平行于时间序列处理过程的传送带，序列中的信息可以在任意位置”跳”上传送带，然后被传送到更晚的时间步，并在需要时原封不动地”跳”过去，接受处理。这就是 LSTM 原理：就像大脑中的记忆存储器，保存信息以便后面使用，我们回忆过去，较早期的信息就又浮现在脑海中，不会随着时间的流逝而消失得无影无踪。

这个思路和残差连接非常相似，其区别在于，残差连接解决的是层与层之间得梯度消失问题，而 LSTM 解决的是循环层与神经元层内循环处理过程中的消息消失问题。

简单来说，C 轨道将携带着跨越时间步的信息。它在不同的时间步的值为 C_t ，这些信息将与输入连接和循环连接进行运算(即与权重矩阵进行点积，然后加上一个偏置，以及加一个激活过程)，从而影响传递到下一个时间步的状态如右图所示。



LSTM-增加了一条记忆轨道，携带序列中较早的信息


2) 建立 LSTM 分类模型，模型参数如下：

编号	参数
1	loss='binary_crossentropy'
2	optimizer='adam'
3	metrics=['acc']

其它参数根据具体数据，具体设置。

3) 神经网络结构及概要

神经网络结构图：



神经网络概要：

Layer (type)	Output Shape	Param #
lstm (LSTM)	(None, 28, 32)	4352
lstm_1 (LSTM)	(None, 50)	16600
dense (Dense)	(None, 10)	510
dense_1 (Dense)	(None, 1)	11
Total params: 21,473		
Trainable params: 21,473		

可以看到每层网络的类型、形状和参数。


7. 模型评估

1) 评估指标主要采用准确率分值、查准率、查全率、F1

编号	评估指标名称	评估指标值
1	查准率	98.74%
2	查全率	100.00%
3	F1	99.37%


通过上述表格可以看出，此模型效果良好。

2) 损失和准确率图




3) ROC 曲线绘制

训练集 ROC 曲线图：



测试集 ROC 曲线图:



8. 临床应用

根据测试集的特征数据，来预测这些患者是否会有相关疾病；根据预测结果：针对将来可能会患有此种疾病的人员，提前进行预防。

预测结果如下：

ani	stinine	eatinine	reatinine	ne_outpu	ine_outp	diuretic	cal_vent	l_toxic	kidney_d	y_pred
		0.7	0		0	0	1	0	1	1
			0			0	0	0	1	1
0.5						1	1	1	0	0
1.2	1.1			1.4	1.4		1	0	0	0
7	1.9	1.2			0.6	0.1	1	1	0	0
	1.4	1.3	-0.1		-0.4	0	0	1	1	1
		0.9	0		-0.8	0	0	0	1	1
		2.4	0.3		5	1	1	1	1	1
0.8			0	1.3		0	0	1	1	1
0.7					2	1	1	1	0	0
0.4	0.7					1	1	1	1	1
0.5	0.9	0.6					1	0	0	0
0.4	0.9	0.7	-0.2	4.4			1	0	1	1